

```
#Model Selection (LightGBM 단독 고속 버전 - 출력 간소화)
```

```
# !sudo apt-get install -y fonts-nanum
```

```
# !sudo fc-cache -fv
```

```
# !rm ~/.cache/matplotlib -rf
```

```
# !pip install lightgbm shap --quiet
```

```
import numpy as np
```

```
import pandas as pd
```

```
pd.options.mode.chained_assignment = None
```

```
import time
```

```
import warnings
```

```
warnings.filterwarnings('ignore')
```

```
from sklearn.model_selection import StratifiedKFold, GridSearchCV, train_test_split
```

```
from sklearn.metrics import roc_auc_score, average_precision_score, make_scorer,  
classification_report
```

```
import lightgbm as lgb
```

```
import shap
```

```
import matplotlib.pyplot as plt
```

```
# STEP 0. 데이터 로딩 및 전처리
```

```
TRAIN_PATH = "Kaggle_Training_Dataset_v2.csv"
```

```
df_raw = pd.read_csv(TRAIN_PATH, low_memory=False)
```

```
BINARY_COLS = ['potential_issue', 'deck_risk', 'oe_constraint', 'ppap_risk', 'stop_auto_buy',  
'rev_stop', 'went_on_backorder']
```

```
for col in BINARY_COLS:
```

```
    if col in df_raw.columns:
```

```
        df_raw[col] = df_raw[col].str.strip().str.upper().map({'YES': 1, 'NO': 0})
```

```

df_raw = df_raw.dropna(subset=['went_on_backorder'])

df_raw['went_on_backorder'] = df_raw['went_on_backorder'].astype(int)


num_cols = df_raw.select_dtypes(include=[np.number]).columns
df_raw[num_cols] = df_raw[num_cols].fillna(df_raw[num_cols].median())


drop_cols = ['went_on_backorder'] + (['sku'] if 'sku' in df_raw.columns else [])
feature_names = [c for c in df_raw.columns if c not in drop_cols]


X = df_raw[feature_names].values
y = df_raw['went_on_backorder'].values


# STEP 1 & 2. LightGBM 단독 학습


scorer = make_scorer(average_precision_score, needs_threshold=True, average="micro")


est = lgb.LGBMClassifier(
    objective='binary', is_unbalance=True, learning_rate=0.05,
    feature_fraction=0.8, bagging_fraction=0.8, bagging_freq=5,
    verbose=-1, n_jobs=-1, random_state=42
)

params = {'num_leaves': [63], 'max_depth': [-1], 'n_estimators': [300]}


X_train, X_test, y_train, y_test = train_test_split(X, y, stratify=y, test_size=0.15, random_state=0)

kf = StratifiedKFold(n_splits=5, shuffle=True, random_state=0)

```

```
gs = GridSearchCV(est, params, cv=kf, scoring=scorer, verbose=0, n_jobs=-1)
```

```
print("학습 진행 중...")
```

```
gs.fit(X_train, y_train)
```

```
lgbm_model = gs.best_estimator_
```

```
y_prob = lgbm_model.predict_proba(X_test)[:, 1]
```

```
y_pred = (y_prob >= 0.5).astype(int)
```

```
# STEP 3. 성능 평가
```

```
print("\n[모델 성능 평가]")
```

```
print(f"ROC-AUC : {roc_auc_score(y_test, y_prob):.4f}")
```

```
print(f"AUPRC : {average_precision_score(y_test, y_prob):.4f}")
```

```
print(classification_report(y_test, y_pred, target_names=['정상(0)', '백오더(1)'], digits=4))
```

```
# STEP 4. SHAP 원인 판독
```

```
bo_idx = np.where(y_pred == 1)[0]
```

```
sample_i = bo_idx[int(np.argmax(y_prob[bo_idx]))] if len(bo_idx) > 0 else int(np.argmax(y_prob))
```

```
pred_prob = y_prob[sample_i]
```

```
true_label = y_test[sample_i]
```

```
print("SHAP 값 계산 중...")
```

```
X_test_df = pd.DataFrame(X_test, columns=feature_names)
```

```
explainer = shap.TreeExplainer(lgbm_model)
```

```
shap_values = explainer(X_test_df)
```

```
# Waterfall Plot 저장 및 출력
```

```
plt.figure(figsize=(10, 6))
```

```
shap.plots.waterfall(shap_values[sample_i], max_display=10, show=False)
```

```

plt.title(f"SHAP Waterfall (Pred: {pred_prob:.1%} | True: {true_label})", fontsize=12)

plt.tight_layout()

plt.savefig('shap_waterfall.png', dpi=150)

plt.show()

# 핵심 원인 텍스트 출력

sv    = shap_values[sample_i].values

fv    = X_test_df.iloc[sample_i].values

top5 = np.argsort(np.abs(sv))[:, -1][:5]

label_map = {

    'national_inv': '현재 재고 수량', 'lead_time': '조달 리드타임', 'in_transit_qty': '운송 중 수량',

    'forecast_3_month': '3개월 예측', 'forecast_6_month': '6개월 예측', 'forecast_9_month': '9개월

    예측',

    'sales_1_month': '1개월 판매량', 'sales_3_month': '3개월 판매량', 'min_bank': '최소 안전재고',

    'pieces_past_due': '납기 초과 수량', 'perf_6_month_avg': '6개월 공급 성과',

    'perf_12_month_avg': '12개월 공급 성과',

    'local_bo_qty': '로컬 백오더 수량', 'deck_risk': 'Deck 위험', 'oe_constraint': 'OE 제약',

    'ppap_risk': 'PPAP 위험', 'stop_auto_buy': '자동 구매 중지', 'rev_stop': '매출 중지',

    'potential_issue': '잠재 이슈'

}

print(f"\n[선택된 샘플 원인 분석 요약]")

print(f"▶ 예측 확률: {pred_prob:.1%} (실제 라벨: {true_label})")

print(f"▶ 주요 위험 요인 Top 5:")

for rank, i in enumerate(top5, 1):

    feat      = feature_names[i]

    kr        = label_map.get(feat, feat)

    direction = "▲위험증가" if sv[i] > 0 else "▽위험감소"

    print(f" {rank}. {kr:<12} | 현재값: {fv[i]:>8.2f} | {direction}")

```

[모델 성능 평가]

ROC-AUC : 0.9660

AUPRC : 0.2939


	precision	recall	f1-score	support
정상(0)	0.9993	0.9180	0.9569	251485
백오더(1)	0.0687	0.8979	0.1276	1694
accuracy			0.9178	253179
macro avg	0.5340	0.9079	0.5422	253179
weighted avg	0.9930	0.9178	0.9513	253179

[선택된 샘플 원인 분석 요약]

▶ 예측 확률: 99.9% (실제 라벨: 1)

▶ 주요 위험 요인 Top 5:

1. 1개월 판매량 | 현재값: 353.00 | ▲위험증가
2. 로컬 백오더 수량 | 현재값: 55.00 | ▲위험증가
3. 12개월 공급 성과 | 현재값: 0.93 | ▲위험증가
4. 6개월 예측 | 현재값: 745.00 | ▲위험증가
5. 9개월 예측 | 현재값: 1005.00 | ▲위험증가



주요 위험 증폭 요인 (Top 10 SHAP Factors)

1. 단기 수요 급증 (sales_1_month: 353.00)

본 예측 모델이 식별한 1위 핵심 원인임. 최근 1개월간 353 단위의 막대한 재고 소모가 발생함. 평소 수준을 크게 상회하는 비정상적인 소모 가속화(Spike) 현상으로 인해 시스템 내 재고 고갈 위험도가 가장 크게 폭등함.

2. 국소적 결품의 선행 발생 (local_bo_qty: 55.00)

중앙 물류센터는 유지되고 있으나, 외곽의 로컬 거점 55곳에서 이미 결품(백오더)이 발생함. 이는 시스템의 전면적 붕괴(글로벌 백오더) 임박을 알리는 가장 확실한 전조 증상(Pre-warning)임.

3. 극단적 부하 상황에서의 공급망 신뢰도 리스크 (perf_12_month_avg: 0.93)

최근 12개월간 공급업체의 정시 납품률은 93%임. 평상시 기준으로는 준수한 수치이나, 단기 소모량이 폭주하여 적기 조달이 필수적인 현 상황에서는 '7%의 조달 지연 및 실패 리스크'가 치명적인 병목(Bottleneck) 요인으로 작용함.

4 & 5. 중장기 막대한 수요의 압박 (forecast_6_month: 745.00 , forecast_9_month: 1005.00)

예측 시스템상 6개월 후 745 단위, 9개월 후 1005 단위의 압도적인 중장기 수요가 대기 중임. 즉, 단기 이슈로 그치지 않고 미래 부하량이 막대하게 산정되어 있어 즉각적이고 대규모의 조달 조치가 불가피함을 시사함.

6. 필수 안전 재고 마지노선 붕괴 위기 (min_bank: 250.00)

해당 품목의 공급망 유지를 위한 최소 안전 재고(Minimum Bank) 기준은 250 단위임. 현재 월 353 단위가 소진되는 속도를 감안할 때, 해당 안전 재고 방어선이 단기간 내 붕괴될 것으로 알고 리즘상 확정 계산됨.

7. 단기 수요 폭발 예측 (forecast_3_month: 620.00)

중장기뿐만 아니라 3개월 후의 단기 예측 수요마저 620 단위로 높게 책정되어 있어, 리드타임 내 재고 확보에 극심한 압박을 가하고 있음.

8. 누적 대비 최근 소모량 비중의 비정상적 증가 (sales_3_month: 674.00)

최근 3개월 총 누적 소모량 674 단위 중 절반 이상(353 단위)이 최근 1개월에 집중됨. 이는 수요가 일정한 것이 아니라 최근 들어 가파르게 폭증(Acceleration)하고 있음을 나타내는 데이터 기반 근거임.

9. 조달(지원 물량)의 절대적 부족 (in_transit_qty: 40.00)

현재 재고 소모는 월 350단위 수준이며 향후 최대 1000단위가 필요한 상황이나, 입고 대기 중인 운송 물량(In-transit)은 40 단위에 불과함. 필요 수요 대비 조달 예정 물량이 절대적으로 부족하여 위험도를 크게 가중시킴.

10. 기타 복합 리스크 요인 (12 other features)

리드타임 딜레이, 운영 위험 플래그(Deck Risk 등)를 포함한 나머지 12개 변수들이 복합적으로 작용하여 시스템의 잔여 방어력을 약화시키고 최종 위험 확률을 99.9%로 견인함.

<모델특징>

LightGBM 기반 타겟 예측 모델링 및 SHAP을 활용한 개별 위험 요인 판독